

팀원 E: MBTI 설문 문항 최적화 — 질문 축소로 정확도 향상 검증

"36개 질문을 20개로 줄이면, 오히려 정확도가 올라갈 수 있을까?"

항목	내용
데이터	자체 밌 설문 v2 응답 94명 (유효 MBTI 81명)
도구	v2 밌 기반 36문항 리커트 척도 (7점), 차원당 9문항
통계	CITC, Cronbach's α , 문항 변별도, SBE, 전수 탐색, Bootstrap 95% CI, Repeated K-Fold CV, Monte Carlo CV
시각화	16개 그래프 (fig.e1 ~ fig.e16)
핵심 질문	노이즈 문항을 제거하면 MBTI 예측 정확도가 향상되는가?

목차

- 0. 읽기 전에
- 1. 연구 개요
- 2. 데이터 및 문항 구조
- 3. 문항 분석 (Item Analysis)
- 4. EI 차원: 문항 선별 상세
- 5. SN 차원: 문항 선별 상세
- 6. TF 차원: 문항 선별 상세
- 7. JP 차원: 문항 선별 상세
- 8. 최적화 탐색 과정
- 9. 원본 vs 최적화 비교
- 10. Bootstrap 교차검증 (과적합 평가)
- 11. 독립 표본 교차검증 (과적합 정량 평가)
- 11.7 고급 최적화 방법 비교 (Advanced Methods)
- 11.9 로지스틱 회귀 MBTI 차원 예측 (fig.e15)
- 11.10 로지스틱 회귀 모형 진단 (fig.e16)
- 12. 종합 결론

범례: 🇧🇷 = 통계 전공자를 위한 심화 해석 | 💡 = 비전공자를 위한 쉬운 설명

0. 읽기 전에

0.1 비전공자를 위한 안내

이 보고서는 **밌 설문 36문항 중 어떤 질문이 MBTI 예측에 도움이 되고, 어떤 질문이 오히려 방해가 되는지**를 분석합니다. "노이즈 문항"이란 설문 응답자의 진짜 성격을 측정하지 못하고 오히려 잡음만 추가하는 질문을 뜻합니다.

핵심 발견: In-sample 최적화에서는 36문항 → 20문항으로 줄이면 38.3% → 51.9%(+13.6%p) 향상되나, **독립 표본 교차검증(K-Fold CV, Monte Carlo CV) 결과, 이 개선은 과적합에 의한 환상임**이 확인되었습니다. 정직한 개선은 -1.9%p로, 문항 축소가 오히려 성능을 저하시킵니다.

추가 발견: 문항 축소 대신 **적응적 임계값(Adaptive Threshold)** 방법으로 차원별 최적 분류 기준점을 탐색한 결과, CV 테스트에서 **40.9%(+2.7%p)**의 **진짜 개선**이 확인되었습니다. 또한 **다수결 투표(Majority Vote)** 방법은 파라미터 없이 **40.7%(+2.4%p)** 개선을 달성하여 과적합 위험이 0%입니다.

0.2 통계 용어 사전

용어	기호	쉬운 설명
CITC	r	수정 문항-총점 상관. "이 문항이 전체 척도와 얼마나 관련되는가?" 0.3 미만 = 약한 문항
Cronbach's α	α	내적 일관성 신뢰도. "이 문항들이 같은 것을 측정하는가?" 0.7 이상이면 양호
α -if-deleted	α_{del}	특정 문항 제거 후 α . 올라가면 → 그 문항이 척도를 해치고 있다는 증거
문항 변별도	D	상위 27%와 하위 27%의 평균 점수 차이. 클수록 변별력이 좋은 문항
예측력	Acc	단일 문항으로 자기보고 MBTI를 맞출 확률. 50% = 동전 던지기 수준
SBE (순차 후진 제거)	—	가장 약한 문항을 하나씩 제거하며 정확도 변화를 추적하는 탐욕적 알고리즘
전수 탐색	—	가능한 모든 문항 조합을 테스트. 9문항 중 3~9개 선택 = 466가지
Bootstrap 95% CI	CI	데이터를 1,000번 재표집하여 추정한 95% 신뢰구간. "이 범위에 참값이 있을 확률 95%"
과적합 (Overfitting)	—	훈련 데이터에만 최적화되어 새 데이터에서는 성능이 떨어지는 문제
LOO-CV	—	Leave-One-Out 교차검증. 한 명씩 빼고 나머지로 검증하는 소표본용 검증법
K-Fold CV	—	K개 그룹으로 나누어 (K-1)개로 훈련, 1개로 평가를 반복하는 교차검증
Monte Carlo CV	—	랜덤으로 훈련/테스트를 분할하여 반복 평가. Random sub-sampling validation
과적합 Gap	—	In-sample 정확도 - CV Test 정확도. 클수록 과적합이 심각
정직한 개선	—	CV Test 최적 정확도 - CV Test 기준선. 독립 데이터에서의 진짜 개선
문항 선택 안정성	—	CV 반복에서 특정 문항이 최적 부분집합에 선택되는 빈도. 80%+ = 안정
적응적 임계값	θ	차원별 최적 분류 기준점. 기본 4.0 대신 데이터에서 최적값(2.0~6.0) 탐색
다수결 투표	MV	각 문항이 독립 투표, 과반수로 분류. 파라미터 없어 과적합 면역
Baseline (기준선)	—	아무 최적화도 하지 않은 "있는 그대로"의 성능. 36문항 전부 + 기본 분류기준(4.0)으로 측정한 정확도. 다른 방법이 이보다 나은지 비교하는 기준점
Subset (문항 부분집합)	—	36문항 중 일부만 골라서 쓰는 방법. 전수 탐색으로 가장 좋은 조합을 찾되, 소표본에서는 과적합 위험이 큼
Sub + Adap	—	문항 부분집합 + 적응적 임계값을 동시에 적용한 조합. 파라미터가 ~20개로 가장 많아 과적합 위험이 가장 높음
CITC + Adap	—	CITC 가중 점수에 적응적 임계값을 결합한 방법. 문항 품질로 가중치를 주면서 분류 기준도 조정
Logistic (로지스틱 회귀)	—	입력 점수에 최적 가중치를 학습하여 확률로 변환, 이진 분류하는 통계 모델. "수학 공식을 데이터에서 학습"
In-Sample (표본 내 평가)	—	학습에 사용한 데이터로 같은 데이터를 평가하는 것. "시험 문제를 미리 본 뒤 같은 문제로 시험 치르기"와 같아서 항상 실제보다 높은 성적이 나옴
로지스틱 회귀 (Logistic Regression)	—	각 문항 응답에 최적 가중치(계수)를 학습하여, 그 합을 확률(0~1)로 변환한 뒤 E인지 I인지(또는 S/N, T/F, J/P)를 분류하는 통계 모델. L2 정규화로 가중치가 너무 커지는 것을 방지

0.3 핵심 메시지 (먼저 읽기)

한 줄 요약: In-sample 최적화에서는 36→20문항으로 38.3%→51.9% 향상되었으나, 독립 표본 교차검증(Repeated 5-Fold CV 100회 + Monte Carlo CV 200회) 결과 **과적합 Gap이 평균 8.5%p로 심각하며, 정직한 개선은 -1.9%p로 오히려 성능이 저하됩니다.** 문항 축소 효과는 과적합에 의한 환상이었습니다. 그러나 **적응적 임계값(Adaptive Threshold)** 방법은 CV 테스트에서 **40.9%(+2.7%p)** 의 진짜 개선을 달성했습니다.

1. 연구 개요

1.1 연구 목적

- **문항 품질 진단:** 차원당 9문항의 심리측정학적 품질(CITC, Cronbach's α , 변별도, 예측력)을 평가
- **노이즈 문항 식별:** 전체 척도의 신뢰도와 예측 정확도를 저해하는 문항 식별
- **최적 문항 부분집합 탐색:** SBE + 전수 탐색으로 정확도를 최대화하는 최소 문항 조합 도출
- **과적합 검증:** Bootstrap 신뢰구간으로 최적화 결과의 안정성 평가
- **실용적 제안:** "더 적은 질문, 더 정확한 예측"이 가능한지 데이터로 확인

1.2 가설 목록

가설	내용	통계 방법	결과
H1	일부 문항의 CITC < 0.3으로 척도 품질을 저해한다	CITC, α -if-deleted	JP 차원 Q40 해당 (CITC=0.045)
H2	약한 문항 제거 시 차원별 정확도가 향상된다	SBE, 전수 탐색	In-sample: 모두 향상, CV: 모두 저하
H3	문항 축소 시 전체 4글자 일치율이 향상된다	최적 부분집합 비교	In-sample: +13.6%p, CV: -1.9%p
H4	최적화 결과는 Bootstrap에서도 안정적이다	Bootstrap 95% CI (1000 회)	CI 겹침 — 과적합 위험
H5	독립 표본에서도 최적화 효과가 유지된다	K-Fold CV + MC CV	기각: 과적합 Gap 8.5%p, 정직한 개선 -1.9%p
H6	대안 최적화(임계값/투표)로 정확도 향상 가능	Repeated 5-Fold CV 100 회	지지: 적응적 임계값 +2.7%p, 다수결 +2.4%p
H7	로지스틱 회귀로 MBTI 차원 예측 가능	LOO-CV (L2 정규화)	평가 완료: 적응적 임계값이 여전히 Best

1.3 사용 통계 방법

검정	구현	용도
CITC (수정 문항-총점 상관)	numpy 수동 구현	문항-척도 관련성 평가 (0.3 미만 = 약한 문항)
Cronbach's α	numpy 수동 구현	내적 일관성 신뢰도 (0.7 이상 = 양호)
α -if-deleted	numpy 수동 구현	문항 제거 효과 (α 가 올라가면 제거 추천)
문항 변별도 (상하 27%)	numpy 수동 구현	고득점/저득점자 구별력 (1.0 미만 = 약함)
단일 문항 예측력	numpy 비교	개별 문항의 자기보고 MBTI 예측 정확도
순차 후진 제거 (SBE)	탐욕 알고리즘	한 문항씩 제거하며 정확도 추적
전수 탐색 (Exhaustive Search)	itertools 조합	C(9,k) 모든 조합 테스트 (466가지/차원)
Bootstrap 95% CI	numpy 재표집	최적화 결과의 안정성/과적합 평가 (1000 회)
Repeated K-Fold CV	numpy 수동 구현	독립 표본 과적합 검증 (5-Fold x 20반복 =100회)
Monte Carlo CV	numpy 수동 구현	랜덤 70/30 분할 반복 검증 (200회)
문항 선택 안정성 분석	numpy 빈도 집계	CV 반복에서 문항 선택 빈도 — 과적합 판단
단순선형회귀	<code>stats_utils.linear_regression()</code>	CITC → 예측력, 변별도 → 예측력 관계 정량화
Pearson 상관분석	<code>stats_utils.pearson_correlation()</code>	CITC와 예측력 간 상관계수 산출
로지스틱 회귀 (Logistic Regression)	numpy 수동 구현 (L2 정규화)	문항 응답으로 MBTI 차원 이진 분류, LOO-CV 검증

1.4 주의사항

- ⚠ **과적합 경고:** 동일 데이터(N=81)에서 최적 문항 조합을 탐색하고 성능을 평가했기 때문에, 결과가 이 특정 표본에 과적합되었을 가능성이 있습니다. 독립 표본에서의 교차검증이 반드시 필요합니다.
- ⚠ **자기보고 기준 한계:** "정확도"의 기준이 자기보고 MBTI(대부분 인터넷 무료 테스트)이므로, 기준 자체의 신뢰도에 한계가 있습니다.

2. 데이터 및 문항 구조

2.1 데이터셋

항목	내용
출처	Google Form 자체 수집 밈 설문 v2 (2026.02)
전체 응답	94명
유효 MBTI	81명 (13명 '모름/미응답' 제외)
문항 수	36문항 (차원당 9문항)
척도	7점 리커트 (1~7)

2.2 차원별 문항 구조

EI 차원 (Q6~Q14): "인싸 vs 아싸"

문항	방향	내용	채점
Q6	I	주말을 침대에서 보내고 싶다	역채점(8-x)
Q7	I	약속 취소됐다는 연락 → 은근히 좋다	역채점(8-x)
Q8	I	주중 회사였으니 주말엔 집에 있어야 한다	역채점(8-x)
Q9	I	놀고 난 후 → 집에서 혼자 충전해야지	역채점(8-x)
Q10	I	몇 개월 집 밖 안 나가도 잘 살 수 있다	역채점(8-x)
Q11	I	당일 갑자기 잡히는 약속이 힘들다	역채점(8-x)
Q12	I	볼일 많으면 하루에 몰아서 끝낸다	역채점(8-x)
Q13	I	새로운 모임 → 집에 빨리 가고 싶다	역채점(8-x)
Q14	I	빈 강의실에 벽 근처에 앉는다	역채점(8-x)

전체 I방향 → 전체 역채점 후 높은 점수 = E(외향). 분류: $\geq 4.0 \rightarrow E$, $< 4.0 \rightarrow I$

SN 차원 (Q15~Q23): "현실주의 vs 몽상가"

문항	방향	내용	채점
Q15	N	과제 깜빡 → 현실적 반응 ↔ 극단적 상상	역채점(8-x)
Q16	N	축제 구경 → 눈앞 무대 ↔ 참가 상상	역채점(8-x)
Q17	N	망상 스타일 → 현실 기반 ↔ 판타지급	역채점(8-x)
Q18	N	드라마 → 고증 체크 ↔ 2차 창작	역채점(8-x)
Q19	N	성과 부진 → 원인 분석 ↔ 파국적 상상	역채점(8-x)
Q20	N	버스 창밖 → 현실적 관찰 ↔ 타인 상상	역채점(8-x)
Q21	N	사과 하면? → 감각적 묘사 ↔ 연상/상징	역채점(8-x)
Q22	N	시험 공부 → 실전 해결책 ↔ 이상 세계 상상	역채점(8-x)
Q23	N	소풍 전날 → 준비 체크리스트 ↔ 만약의 시나리오	역채점(8-x)

전체 역채점 후 높은 점수 = S(감각). 분류: $\geq 4.0 \rightarrow S$, $< 4.0 \rightarrow N$

TF 차원 (Q24~Q32): "너 T야?"

문항	방향	내용	채점
Q24	F	친구 고민 → 해결책 제시 ↔ 공감 먼저	역채점(8-x)
Q25	F	"아무도 안 좋아해" → 답답 ↔ 속상	역채점(8-x)
Q26	F	"아는 척 하지마" → 논리 반박 ↔ 감정 상처	역채점(8-x)
Q27	F	친구 차 사고 → 보험사 불렀어? ↔ 괜찮아?	역채점(8-x)
Q28	F	"재능 있다!" → 팩트 집중 ↔ 뉘앙스 집중	역채점(8-x)
Q29	F	칭찬 스타일 → 객관적 ↔ 공감형	역채점(8-x)
Q30	F	"나 살 찌지?" → 솔직 팩트 ↔ 감성 케어	역채점(8-x)
Q31	F	"죽을 수 있어" → 팩트 폭격 ↔ 감정 보호	역채점(8-x)
Q32	F	설문 부탁 → 귀찮음 솔직 ↔ 의리 챙김	역채점(8-x)

전체 역채점 후 높은 점수 = T(사고). 분류: $\geq 4.0 \rightarrow T$, $< 4.0 \rightarrow F$

JP 차원 (Q33~Q41): "계획충 vs 즉흥충"

문항	방향	내용	채점
Q33	P	여행 준비 → 엑셀 완벽 계획 ↔ 발길 닿는 대로	역채점(8-x)
Q34	P	스마트폰 → 0개 알림 ↔ 999+ 기본	역채점(8-x)
Q35	P	식당 휴업 → 플랜 B ↔ 즉석 발견	역채점(8-x)
Q36	P	마감 과제 → 미리미리 ↔ 전날 버락치기	역채점(8-x)
Q37	P	여행 짐 → 체크리스트 ↔ 대충 꾸서넣기	역채점(8-x)
Q38	P	마트 → 리스트대로 ↔ 총동 장바구니	역채점(8-x)
Q39	P	방/책상 → 각 잡힌 정리 ↔ 나만의 카오스	역채점(8-x)
Q40	P	요리 → 정량 정순서 ↔ 감으로 대충	역채점(8-x)
Q41	P	금요일 밤 → 타임라인 완성 ↔ 알람 OFF 늦잠	역채점(8-x)

전체 역채점 후 높은 점수 = J(판단). 분류: $\geq 4.0 \rightarrow J$, $< 4.0 \rightarrow P$


2.3 기존 정확도 (최적화 전 기준선)

차원	일치율 (9문항)	해석
EI	80.2%	양호
SN	70.4%	보통
TF	75.3%	양호
JP	81.5%	양호
전체 4글자	38.3%	부족 (차원 곱)

 **쉬운 설명:** 각 차원은 70~82%로 꽤 괜찮은데, 4개를 동시에 맞춰야 하는 전체 일치율은 38.3%로 낮습니다. 시험 4과목에서 각각 75점을 받아도 "전 과목 만점"은 어려운 것과 같습니다.

3. 문항 분석 (Item Analysis)

3.1 fig_e1: 수정 문항-총점 상관 (CITC) 히트맵



시각화 방법: 2x2 서브플롯, 차원별 수평 막대 차트 (문항별 CITC)

사용 이유: 각 문항이 해당 차원의 전체 점수와 얼마나 일관성 있게 관련되는지 평가. CITC < 0.3이면 해당 문항이 같은 것을 측정하지 않을 가능성

사용 변수: 차원별 9문항 채점 후 점수

결과 해석:

차원	α	CITC 범위	CITC < 0.3 문항	비고
EI	0.874	0.446 ~ 0.735	없음	전체적으로 양호
SN	0.816	0.388 ~ 0.627	없음	전체적으로 양호
TF	0.857	0.350 ~ 0.699	없음	Q28 상대적으로 낮음
JP	0.761	0.045 ~ 0.668	Q40 (0.045)	Q40 심각하게 약한 문항


통계적 관점:

JP 차원의 Q40 (CITC=0.045): "요리 → 정량 정순서 ↔ 감으로 대충" 문항이 JP 척도와 거의 무관합니다. CITC=0.045 수준은 사실상 **랜덤 잡음**에 가까우며, 이 문항이 J/P 차원의 "계획성 vs 즉흥성"과 독립적으로 반응함을 의미합니다. 요리 스타일은 J/P 성향보다 **요리 경험이나 개인 습관**에 더 의존할 가능성이 높습니다.

TF 차원의 Q28 (CITC=0.350): "재능 있다! → 팩트 집중 ↔ 뉘앙스 집중" 문항이 0.3 기준을 간신히 통과합니다. 팩트/뉘앙스 구분이 T/F보다 S/N 차원(사실 vs 해석)에 더 가까울 수 있습니다.

💡 **쉬운 설명:** CITC는 "이 질문이 다른 질문들과 같은 성격을 측정하는가?"를 보여줍니다. 빨간색(0.3 미만)인 문항은 "엉뚱한 질문"입니다. Q40(요리 스타일)은 계획적인지 즉흥적인지와 거의 관련이 없었습니다 — 요리를 감으로 하는 것은 J/P 성격이 아니라 요리 실력의 문제일 수 있습니다.

3.2 fig_e2: Cronbach's α 변화 (문항 제거 시)



시각화 방법: 2x2 서브플롯, α -if-deleted 수평 막대 + 현재 α 기준선

사용 이유: 특정 문항을 제거했을 때 α 가 올라가면, 그 문항이 척도의 내적 일관성을 해치고 있다는 증거

사용 변수: 차원별 9문항 채점 후 점수

결과 해석:

차원	현재 α	α ↑ 문항 (제거 시 향상)	변화량
EI	0.874	없음	—
SN	0.816	없음	—
TF	0.857	Q28 ($\alpha \rightarrow 0.863$)	+0.006 (미미)
JP	0.761	Q40 ($\alpha \rightarrow 0.796$)	+0.035 (유의)


📊 **통계적 관점:**

Q40 제거 시 α 변화 (0.761→0.796): +0.035의 변화는 심리측정학적으로 의미 있는 수준입니다. 이는 Q40이 JP 척도의 내적 일관성을 적극적으로 해치고 있음을 확인합니다. CITC=0.045과 결합하면, Q40은 **제거 1순위 문항**입니다.

EI, SN, TF 차원: 어떤 문항을 제거해도 α 가 의미 있게 변하지 않아, 문항 구성이 비교적 양호합니다.

💡 **쉬운 설명:** 검은 세로선(현재 α)보다 오른쪽에 있는 빨간 막대는 "이 질문을 빼면 전체 신뢰도가 올라간다"는 뜻입니다. Q40만 뚜렷하게 빨간색이며, 이 질문이 JP 차원을 측정하는 데 오히려 방해가 되고 있습니다.

3.3 fig_e3: 문항 변별도 (상위/하위 27% 차이)



시각화 방법: 2x2 서브플롯, 상위 27% 평균 - 하위 27% 평균 차이

사용 이유: 변별도가 높은 문항은 고득점자와 저득점자를 잘 구별함. 1.0 미만이면 변별력 부족


결과 해석:

차원	변별도 범위	약한 문항 (<1.0)
EI	2.429 ~ 4.190	없음
SN	2.429 ~ 3.429	없음
TF	2.524 ~ 4.429	없음
JP	1.095 ~ 3.762	Q40 (1.095)

통계적 관점: Q40의 변별도 1.095는 7점 척도에서 상하 27% 그룹 간 겨우 1점 차이입니다. 이는 JP 총점이 높은 사람(J 성향)과 낮은 사람(P 성향) 사이에 Q40 응답 패턴이 거의 동일함을 의미합니다. 반면 Q33(여행 준비)은 3.762로, J/P를 가장 잘 구별하는 문항입니다.

쉬운 설명: 변별도는 "계획적인 사람과 즉흥적인 사람이 이 질문에 다르게 답하는가?"를 보여줍니다. Q40(요리 스타일)은 두 그룹이 거의 비슷하게 답해서, J인지 P인지 구별하는 데 쓸모가 없습니다.

3.4 fig_e4: 문항별 자기보고 MBTI 예측 정확도



시각화 방법: 2x2 서브플롯, 단일 문항 예측 정확도 (%) 수평 막대

사용 이유: 각 문항 하나만으로 자기보고 MBTI의 해당 차원을 맞출 수 있는 확률을 측정. 50% = 동전 던지기

결과 해석:

차원	최고 예측력 문항	최저 예측력 문항
EI	Q14 (80.2%)	Q10 (61.7%)
SN	Q18 (71.6%)	Q22 (61.7%)
TF	Q24 (77.8%)	Q26 (63.0%), Q28 (64.2%)
JP	Q39 (76.5%)	Q40 (53.1%)

통계적 관점:

Q40의 예측력 53.1%: 이진 분류에서 우연 수준(50%)과 불과 3.1%p 차이입니다. 이항 검정에서 $N=81$, $p=0.531$ 이면 $p\text{-value} \approx 0.39$ 로, 동전 던지기와 통계적으로 구분되지 않습니다. Q40은 CITC(0.045), $\alpha\text{-if-deleted}$ (0.7961), 변별도(1.095), 예측력(53.1%) **모든 지표에서 최하위**입니다.

EI 차원의 Q14 (80.2%): "빈 강의실에 벽 근처에 앉는다"가 단일 문항으로 EI를 80% 맞추는 것은 인상적입니다. 이는 좌석 선택이 외향/내향 성향을 매우 직접적으로 반영하는 행동이기 때문입니다.

쉬운 설명: 질문 하나만으로 E인지 I인지를 맞출 수 있을까요? Q14("빈 강의실에서 어디에 앉나?")는 80.2% 정확도로 최고입니다. 반면 Q40("요리할 때 계량하나?")는 53.1%로 동전 던지기과 같습니다.

3.5 회귀분석: CITC → 예측력 관계 정량화

핵심 질문: 내적 일관성(CITC)이 높은 문항이 실제로 자기보고 MBTI를 잘 예측하는가?

분석 배경: CITC와 예측력은 서로 다른 개념이다. CITC는 "문항이 같은 척도의 나머지 문항과 일관된가"(내적 기준), 예측력은 "문항이 자기보고 MBTI를 맞추는가"(외적 기준)이다. 이 두 지표의 관계를 회귀분석으로 정량화한다.

차원별 CITC → 예측력 회귀

차원	회귀식	R ²	해석
EI	예측력 = $-0.002 \times \text{CITC} + 0.685$	0.0000	CITC가 예측력을 거의 설명 못함
SN	예측력 = $0.003 \times \text{CITC} + 0.669$	0.0000	CITC가 예측력을 거의 설명 못함
TF	예측력 = $0.267 \times \text{CITC} + 0.531$	0.2680	CITC가 예측력의 26.8% 설명
JP	예측력 = $0.343 \times \text{CITC} + 0.522$	0.7885	CITC가 예측력의 78.9% 설명

차원별 차이의 해석:

- **EI, SN:** CITC와 예측력이 거의 무관 → 내적 일관성이 높아도 예측력이 높다는 보장 없음
- **TF:** 보통 수준의 관계 ($R^2=0.27$) → CITC가 높은 문항이 예측력도 약간 높은 경향
- **JP:** 매우 강한 관계 ($R^2=0.79$) → JP 차원에서는 CITC가 높으면 예측력도 높음

전체 36문항 통합 회귀분석

회귀 모형	회귀식	R ²	유의성	해석
CITC → 예측력	예측력 = $0.193 \times \text{CITC} + 0.576$	0.214	*	CITC 1단위 증가 시 예측력 19.3%p 향상
변별도 → 예측력	예측력 = $0.037 \times \text{변별도} + 0.583$	0.234	*	변별도 1단위 증가 시 예측력 3.7%p 향상
CITC ↔ 예측력 상관	$r = 0.463$	$R^2=0.214$	*	보통 수준의 양의 상관

통계적 관점: 전체 36문항에서 CITC→예측력 $R^2=0.214$ 는 "보통 효과"(Cohen: 0.13~0.26)에 해당한다. 이는 CITC가 예측력의 **약 21%를 설명**하지만, 나머지 79%는 CITC 외 요인에 의해 결정됨을 의미한다. 특히 EI($R^2=0.0000$)와 JP($R^2=0.7885$)의 극적인 차이는, **차원에 따라 내적 일관성과 외적 예측력의 관계가 근본적으로 다름**을 보여준다. EI 차원에서는 Q14(벽쪽 앉기)처럼 CITC가 낮아도(0.457) 예측력이 높은(80.2%) 문항이 존재하며, 이는 "행동 직접 관찰" 유형의 문항이 CITC와 독립적으로 높은 기준 타당도를 가질 수 있음을 시사한다.

변별도→예측력 $R^2=0.234$ 도 유의하며, **변별도가 CITC보다 예측력과 약간 더 관련됨**을 보여준다.

💡 쉬운 설명: "다른 질문들과 잘 어울리는 질문(CITC 높음)이 실제로 MBTI를 잘 맞추는가?" — 전체적으로는 **약간의 관련 (21%)**이 있습니다. 그러나 차원마다 크게 다릅니다: - **JP 차원:** 다른 질문과 잘 어울리는 질문이 실제로도 잘 맞습니다 (79% 관련) - **EI 차원:** 다른 질문과 잘 어울려도, 실제로 E/I를 맞추는 것과는 거의 무관합니다 (0.00% 관련)

이는 "좋은 질문"을 판단하는 기준이 하나가 아니라는 것을 보여줍니다. CITC만 보고 문항을 선별하면 안 되고, 실제 예측력도 함께 봐야 합니다.

4. EI 차원: 문항 선별 상세

4.1 문항별 심리측정 지표 종합

문항	CITC	α 삭제	변별도	예측력	최적화 결과	선별 근거
Q6	0.699	0.853	3.571	65.4%	제거	예측력 65.4%: 양호하나 최적 조합에 불필요
Q7	0.596	0.862	3.857	65.4%	제거	CITC 대비 예측력이 상대적으로 낮음
Q8	0.724	0.849	4.190	66.7%	제거	높은 CITC지만 최적 3문항 조합에서 제외
Q9	0.735	0.846	4.000	76.5%	유지	CITC 최고(0.735) + 높은 예측력(76.5%)
Q10	0.639	0.858	4.143	61.7%	제거	예측력 최저(61.7%)
Q11	0.521	0.868	3.333	63.0%	제거	CITC와 예측력 모두 상대적으로 낮음
Q12	0.446	0.872	2.429	69.1%	제거	낮은 CITC(0.446) + 낮은 변별도(2.429)
Q13	0.719	0.851	3.619	77.8%	유지	높은 CITC(0.719) + 2위 예측력(77.8%)
Q14	0.457	0.875	2.810	80.2%	유지	예측력 최고(80.2%) — 핵심 문항

4.2 최적 조합: {Q9, Q13, Q14} — 3문항

정확도: 80.2% → **85.2%** ($\Delta = +4.9\%$)

선별 논리:

유지 문항	역할
Q9	"놀고 난 후 충전" — CITC 최고(0.735), 예측력 76.5%. 핵심 EI 측정 문항
Q13	"모임 후 빨리 집" — CITC 0.719, 예측력 77.8%. EI 직접 행동 지표
Q14	"벽 근처에 앉기" — 예측력 80.2%로 최고. 비언어적 EI 행동 포착

제거 문항 분석:

제거 문항	제거 이유
Q6	"주말 침대" — 예측력 65%. 내향뿐 아니라 피로/게으름도 측정할 수 있음
Q7	"약속 취소 좋다" — 예측력 65%. 약속의 종류에 따라 반응이 달라짐
Q8	"주말엔 집" — 높은 CITC(0.724)이나 Q9와 의미 중복 (에너지 충전 관련)
Q10	"몇 개월 안 나가도" — 예측력 최저(61.7%). 극단적 표현이 반응 왜곡
Q11	"당일 약속 힘들다" — 계획성(JP)과 혼동 가능
Q12	"불일 몰아서" — 낮은 CITC(0.446). 효율성 추구는 EI보다 JP에 가까움

 **통계적 관점:** EI 차원에서 9문항 → 3문항으로 67% 감소하면서도 정확도가 +4.9%p 향상된 것은, 제거된 6개 문항이 **노이즈 기여자**였음을 시사합니다. 특히 Q8(CITC=0.724)처럼 CITC가 높은 문항도 제거된 것은, CITC가 "내적 일관성"은 측정하지만 "자기보고 예측력"과 반드시 일치하지 않음을 보여줍니다.

 **쉬운 설명:** EI(외향/내향)를 가장 잘 예측하는 3개 질문은: 1. "놀고 나서 혼자 충전해야 하나?" (Q9) 2. "모임에서 빨리 집에 가고 싶은가?" (Q13) 3. "빈 강의실에서 벽 근처에 앉는가?" (Q14)

이 3개만으로 85.2%를 맞출 수 있습니다. "주말에 침대에 있고 싶다"(Q6)나 "몇 개월 안 나가도 된다"(Q10) 같은 질문은 내향적이지 아니라 그냥 **피곤하거나 게으른** 사람도 높게 답할 수 있어서 빠졌습니다.

5. SN 차원: 문항 선별 상세

5.1 문항별 심리측정 지표 종합

문항	CITC	α 삭제	변별도	예측력	최적화 결과	선별 근거
Q15	0.552	0.794	2.619	65.4%	유지	최적 4문항 조합에 포함
Q16	0.627	0.784	2.952	70.4%	제거	CITC 높으나 최적 조합에 불필요
Q17	0.506	0.800	3.429	71.6%	제거	높은 변별도이나 최적 조합 제외
Q18	0.487	0.800	2.429	71.6%	유지	예측력 최고(71.6%)
Q19	0.561	0.793	2.762	66.7%	제거	예측력 상대적으로 낮음
Q20	0.457	0.805	3.143	67.9%	유지	최적 4문항 조합에 포함
Q21	0.388	0.811	2.476	65.4%	제거	가장 낮은 CITC(0.388) + α ↑가능
Q22	0.558	0.793	2.571	61.7%	제거	예측력 최저(61.7%)
Q23	0.516	0.798	3.238	66.7%	유지	높은 변별도(3.238)

5.2 최적 조합: {Q15, Q18, Q20, Q23} — 4문항

정확도: 70.4% → **75.3%** ($\Delta = +4.9\%p$)

선별 논리:

유지 문항	역할
Q15	"과제 깜빡 반응" — 현실적 vs 상상적 반응의 직접 대비
Q18	"드라마 → 고증 vs 2차 창작" — 예측력 최고(71.6%). 콘텐츠 소비 방식 차이
Q20	"버스 창밖 관찰" — 일상 행동에서의 S/N 차이 포착
Q23	"소풍 전날 준비" — 높은 변별도(3.238). 실제 행동 예측과 연결

제거 문항 분석:

제거 문항	제거 이유
Q16	"축제 상상" — 높은 CITC(0.627)이나 Q15와 상황 유사 (상상 vs 현실)
Q17	"망상 스타일" — "망상"이라는 단어가 부정적 뉘앙스로 반응 왜곡 가능
Q19	"성과 부진 → 파국적 상상" — 불안(neuroticism)과 혼동 가능
Q21	"사과 하면?" — 가장 낮은 CITC(0.388). 추상적 질문이 S/N 구분에 부적합
Q22	"시험 → 이상 세계" — 예측력 최저(61.7%). 비현실적 상황 설정

 **통계적 관점:** SN 차원은 9문항 전체의 CITC 범위가 0.388~0.627로, 다른 차원(EI: 0.446~0.735, TF: 0.350~0.699)에 비해 상대적으로 좁습니다. 이는 SN 문항들이 전반적으로 비슷한 수준의 척도 기여도를 가지며, "뚜렷한 약한 문항"이 없다는 뜻입니다. 따라서 5개를 제거해도 +4.9%p 향상에 그쳤습니다.

 **쉬운 설명:** S/N(감각/직관)을 묻는 질문 중에서는 "드라마 볼 때 고증을 체크하나, 2차 창작을 상상하나?"(Q18)가 가장 예측력이 높았습니다(71.6%). "사과 하면 뭐가 떠오르나?"(Q21)는 너무 추상적이어서, S형이든 N형이든 비슷하게 답했습니다.

6. TF 차원: 문항 선별 상세

6.1 문항별 심리측정 지표 종합

문항	CITC	α 삭제	변별도	예측력	최적화 결과	선별 근거
Q24	0.699	0.835	4.286	77.8%	유지	CITC 최고(0.699) + 예측력 최고
Q25	0.621	0.842	4.095	70.4%	제거	양호하나 최적 5문항 조합에서 제외
Q26	0.621	0.842	4.143	63.0%	제거	예측력 최저(63.0%)
Q27	0.665	0.838	4.190	72.8%	유지	높은 CITC + 변별도 + 예측력
Q28	0.350	0.863	2.524	64.2%	유지	CITC 최저이나 최적 조합에 기여
Q29	0.543	0.848	4.048	71.6%	제거	Q24, Q27과 유사한 공감 관련 문항
Q30	0.550	0.849	3.619	64.2%	제거	Q27과 의미 중복 (팩트 vs 감성)
Q31	0.626	0.839	4.429	67.9%	유지	변별도 최고(4.429)
Q32	0.559	0.849	3.952	71.6%	유지	양호한 전 지표, 최적 조합 기여

6.2 최적 조합: {Q24, Q27, Q28, Q31, Q32} — 5문항

정확도: 75.3% → **84.0%** ($\Delta = +8.6\%p$) ← **최대 개선 차원**

선별 논리:

유지 문항	역할
Q24	"친구 고민 → 해결책 vs 공감" — TF의 전형적 밈. CITC 최고(0.699) + 예측력 최고
Q27	"친구 사고 → 보험 vs 괜찮아?" — 가장 유명한 T/F 밈. 직관적 문항
Q28	"재능 → 팩트 vs 뉘앙스" — CITC는 낮으나(0.350), 다른 문항이 놓치는 정보 포착
Q31	"죽을 수 있어 → 팩트 vs 감정" — 변별도 최고(4.429). 극한 상황에서 TF 차이 뚜렷
Q32	"설문 부탁 → 솔직 vs 의리" — 실제 행동 관련. 사회적 상황에서의 TF

제거 문항 분석:

제거 문항	제거 이유
Q25	"아무도 안 좋아해 → 담담 vs 속상" — 자존감/정서 안정성과 혼동 가능
Q26	"아는 척 하지마" — 예측력 최저(63.0%). 자존심/공격성과 혼동
Q29	"칭찬 스타일 → 객관 vs 공감" — Q24와 의미 중복 (논리적 vs 감정적 반응)
Q30	"살 찌지? → 팩트 vs 감성" — Q27과 유사 (솔직 vs 배려). 중복 제거

 **통계적 관점:** TF 차원에서 +8.6%p의 최대 개선이 나타난 것은 주목할 만합니다. 흥미롭게도 CITC가 가장 낮은 Q28(0.350)이 최적 조합에 포함되었습니다. 이는 Q28이 다른 문항들과 **상관이 낮지만**(낮은 CITC), 다른 문항들이 놓치는 **고유한 T/F 정보**를 제공하기 때문입니다. 심리측정학적으로 "내적 일관성에 기여하지 않지만 외적 기준(자기보고)에 기여하는 문항"의 전형적 사례입니다.

 **쉬운 설명:** T/F 차원에서 가장 큰 개선(+8.6%p)이 있었습니다. 재미있는 발견은, CITC가 가장 낮은 Q28("재능 있다! → 팩트 vs 뉘앙스")이 오히려 최적 조합에 포함된 것입니다. 다른 질문들은 주로 "논리 vs 감정"을 물었는데, Q28은 "사실 vs 해석"이라는 약간 다른 각도를 제공해서, 전체적으로 더 정확해진 것입니다.

7. JP 차원: 문항 선별 상세

7.1 문항별 심리측정 지표 종합

문항	CITC	α 삭제	변별도	예측력	최적화 결과	선별 근거
Q33	0.668	0.709	3.762	72.8%	유지	CITC 최고 + 변별도 최고
Q34	0.317	0.757	2.952	69.1%	유지	알림 관리라는 고유한 J/P 행동 포착
Q35	0.392	0.752	2.143	61.7%	유지	위기 대처 방식에서 J/P 차이
Q36	0.475	0.740	3.429	72.8%	유지	마감 관리 — 전형적 J/P 문항
Q37	0.567	0.725	3.286	70.4%	제거	양호하나 Q33(여행)과 의미 중복
Q38	0.566	0.726	3.381	72.8%	유지	쇼핑 습관에서의 J/P 차이
Q39	0.562	0.726	3.238	76.5%	유지	예측력 최고(76.5%) — 정리 정돈 습관
Q40	0.045	0.796	1.095	53.1%	유지	CITC 극히 낮으나 전수 탐색에서 포함
Q41	0.435	0.740	3.095	70.4%	유지	주말 계획 — 실생활 J/P 행동

7.2 최적 조합: {Q33~Q36, Q38~Q41} — 8문항 (Q37만 제거)

정확도: 81.5% → **86.4%** ($\Delta = +4.9\%p$)

제거 문항 분석:

제거 문항	제거 이유
Q37	"여행 짐 → 체크리스트 vs 대충" — Q33(여행 계획)과 의미 중복 . 둘 다 여행 관련 계획성을 묻지만, Q33(전체 계획)이 Q37(짐 싸기)보다 더 포괄적. CITC는 0.567로 양호하나, Q33과 같이 있으면 다중공선성 효과로 노이즈 증가

 통계적 관점:

Q40의 역설적 유지: CITC=0.045, 변별도=1.095, 예측력=53.1%로 모든 지표에서 최악이지만, 전수 탐색 결과 8문항 최적 조합에 포함되었습니다. 이는 다음과 같이 해석됩니다:

- 소표본 효과:** N=81에서 1~2명의 응답 변동이 결과를 바꿀 수 있음
- 문항 간 상호작용:** Q40 단독으로는 약하지만, 나머지 7문항과 결합하면 미세한 정보를 추가할 가능성
- 과적합 가능성:** 이 특정 표본에서만 Q40이 우연히 기여하는 것일 수 있음


α -if-deleted 분석에서 Q40 제거 시 α 가 0.761→0.796로 상승하므로, **신뢰도 관점에서는 제거가 권장**되지만, **예측 정확도 관점에서는 유지가 유리**한 모순적 상황입니다. 이는 독립 표본 검증 시 변경될 가능성이 높습니다.

 **쉬운 설명:** JP 차원에서는 Q37("여행 짐 싸기")만 제거되었습니다. Q33("여행 계획")과 비슷한 내용이라 중복되기 때문입니다.

흥미로운 점은 Q40("요리할 때 계량하나?")이 모든 지표에서 최악인데도 최적 조합에 남은 것입니다. 이는 81명이라는 작은 데이터에서 우연히 약간의 기여를 했을 가능성이 높으며, 더 많은 사람으로 재검증하면 결과가 달라질 수 있습니다.

8. 최적화 탐색 과정

8.1 fig_e5: 순차 후진 제거 (SBE) 곡선



시각화 방법: 2x2 서브플롯, 문항 수 vs 정확도 곡선

사용 이유: 한 문항씩 제거할 때의 정확도 변화를 추적하여, 문항 수와 성능의 트레이드오프를 시각화


결과 해석:

차원	SBE 최적점	SBE 최적 정확도
EI	4문항 (Q8제거 시점)	84.0%
SN	6문항 (Q16제거 시점)	75.3%
TF	5문항 (Q30제거 시점)	81.5%
JP	8문항 (Q36제거 시점)	86.4%

통계적 관점: SBE는 **탐욕 알고리즘**이므로, 각 단계에서 지역 최적(locally optimal)인 문항을 제거합니다. 그러나 전역 최적(globally optimal)과 다를 수 있습니다. 예를 들어 EI에서 SBE 최적은 4문항(84.0%)이지만, 전수 탐색 최적은 3문항(85.2%)입니다. 이는 SBE가 "Q6 제거 → Q10 제거 → ..." 경로를 따라가면서 {Q9, Q13, Q14} 조합에 도달하지 못한 것입니다.

쉬운 설명: 가장 약한 질문부터 하나씩 빼면서 정확도가 어떻게 변하는지 추적한 그래프입니다. 빨간 별이 "이만큼 빼면 가장 좋다"는 최적점입니다. 하지만 이 방법은 "하나씩 순서대로 빼는" 방식이라, 모든 가능한 조합 중 최고를 놓칠 수 있습니다. 그래서 아래의 전수 탐색도 함께 했습니다.

8.2 fig_e6: 차원당 최적 k문항 → 전체 4글자 일치율



시각화 방법: 단일 플롯, 차원당 동일 k문항 사용 시 전체 일치율 곡선 + 차원별 곡선

사용 이유: "차원당 몇 문항이 전체 MBTI 예측에 최적인가?"를 한눈에 확인


결과 해석:

차원당 문항 수	총 문항	전체 4글자 일치율
3문항	12	47.5%
4문항	16	47.5%
5문항	20	51.9%
6문항	24	46.9%
7문항	28	42.0%
8문항	32	42.0%
9문항	36	38.3%

차원당 5문항(총 20문항)이 전체 일치율 최고 (51.9%)

통계적 관점: 이 그래프는 "모든 차원에 동일한 k를 적용"했을 때의 결과입니다. 실제 최적화에서는 차원마다 다른 k를 적용(EI:3, SN:4, TF:5, JP:8)하여 동일한 51.9%를 달성했습니다. 흥미롭게도 k=5 균일과 비균일 최적화가 같은 결과를 내어, 비균일 최적화의 추가 이점이 전체 일치율 수준에서는 미미합니다.

8.3 fig_e7: 전수 탐색 — 문항 수별 정확도 분포



시각화 방법: 2x2 서브플롯, 각 차원별 문항 수 vs 정확도 swarm plot + 최적선

사용 이유: 각 문항 수에서 가능한 모든 조합의 정확도 분포를 보여주어, 최적 조합이 얼마나 독보적인지 평가

결과 해석:


차원	탐색 조합 수	최적 k	최적 정확도	최악 정확도 (같은 k)	변동 폭
EI	466	3	85.2%	55.6% (3문항 최악)	29.6%p
SN	466	4	75.3%	63.0% (4문항 최악)	12.3%p
TF	466	5	84.0%	72.8% (5문항 최악)	11.1%p
JP	466	8	86.4%	82.7% (8문항 최악)	3.7%p

통계적 관점: EI 차원에서 3문항 조합의 변동 폭이 29.6%p(55.6~85.2%)로 가장 큼니다. 이는 EI 3문항 중 어떤 조합을 선택하느냐에 따라 결과가 극적으로 달라진다는 의미입니다. 반면 JP 8문항은 3.7%p 범위로, 어떤 1개를 빼도 비슷한 성능을 보여 **견고한(robust) 결과**입니다. EI의 높은 변동성은 과적합 위험 신호이기도 합니다.

쉬운 설명: 각 점은 "이 질문 조합을 사용했을 때의 정확도"입니다. 점이 넓게 퍼져 있으면 "어떤 질문을 고르느냐에 따라 크게 달라진다"는 뜻이고, 좁으면 "뭘 골라도 비슷하다"는 뜻입니다. EI 3문항은 조합에 따라 55.6%~85.2%로 큰 차이가 나서, 우리가 찾은 최적 조합이 "운이 좋았을" 가능성도 있습니다.

9. 원본 vs 최적화 비교

9.1 fig_e8: 원본 (36문항) vs 최적화 정확도



시각화 방법: 2패널 (좌: 차원별 비교 막대, 우: 전체 4글자 비교 막대)

사용 이유: 최적화 전후의 정확도를 직관적으로 비교

결과 종합:

차원	원본 (9문항)	최적화	문항 수 변화	변화
EI	80.2%	85.2%	9 → 3	+4.9%p
SN	70.4%	75.3%	9 → 4	+4.9%p
TF	75.3%	84.0%	9 → 5	+8.6%p
JP	81.5%	86.4%	9 → 8	+4.9%p
전체 4글자	38.3%	51.9%	36 → 20	+13.6%p

통계적 관점:

전체 일치율 개선의 비선형성: 차원별 +4.9~+8.6%p의 개선이 전체에서는 +13.6%p로 확대됩니다. 이는 4개 차원의 곱셈 효과 때문입니다:


- 원본: $0.80 \times 0.70 \times 0.75 \times 0.82 = 34.6\%$ (이론적 상한, 실측 38.3%)
- 최적: $0.85 \times 0.75 \times 0.84 \times 0.86 = 46.1\%$ (이론적 상한, 실측 51.9%)
- 이론적 차이: +11.5%p, 실측 차이: +13.6%p

실측이 이론보다 높은 것은 차원 간 양의 상관(한 차원을 맞추면 다른 차원도 맞출 확률 상승)이 존재하기 때문입니다.

TF 차원의 최대 개선 (+8.6%p): 9문항 중 4개를 제거했을 뿐인데 8.6%p 향상은, 제거된 4문항(Q25, Q26, Q29, Q30)이 상당한 노이즈를 추가하고 있었음을 시사합니다. 특히 Q25("아무도 안 좋아해")와 Q26("아는 척 하지마")은 T/F보다 자존감이 나 정서 반응성(neuroticism)을 측정할 가능성이 있습니다.

💡 쉬운 설명: 36문항 중 16개를 빼고 20개만 쓰면, 정확도가 38.3%에서 51.9%로 올랐습니다. "질문을 줄이면 정확도가 떨어진다"는 직관과 반대되는 결과입니다. 이는 제거된 16개 질문이 "잡음(노이즈)"을 추가하여 오히려 방해했기 때문입니다. 마치 시험에서 어려운 문제를 제외하면 평균 점수가 오르는 것과 비슷합니다.

9.2 fig_e9: 차원별 문항 기여도 종합 순위



시각화 방법: 2×2 서브플롯, CITC + 변별도 + 예측력의 정규화 합 기준 순위 (누적 막대)

사용 이유: 3가지 기여도 지표를 하나의 종합 순위로 합산하여, 문항 중요도를 직관적으로 비교

결과 해석: ★ 표시가 최적 부분집합에 포함된 문항입니다. 종합 순위와 최적 부분집합이 반드시 일치하지 않는 점이 흥미롭습니다 — 이는 문항 간 **조합 효과**가 존재하기 때문입니다.

10. Bootstrap 교차검증 (과적합 평가)

10.1 Bootstrap 방법론

설정	값
재표집 횟수	1,000회
표본 크기	N=81 (복원 추출)
신뢰구간	95% (백분위수법: 2.5%~97.5%)
비교 대상	원본(9문항) vs 최적화(k문항) — 차원별

10.2 Bootstrap 결과

차원	원본 평균 (95% CI)	최적 평균 (95% CI)	CI 겹침	판정
EI	80.3% [71.6%, 88.9%]	85.2% [77.8%, 92.6%]	겹침	유의하지 않을 수 있음
SN	70.4% [60.5%, 80.2%]	75.3% [65.4%, 84.0%]	겹침	유의하지 않을 수 있음
TF	75.5% [66.6%, 84.0%]	84.0% [76.5%, 91.4%]	겹침	유의하지 않을 수 있음
JP	81.4% [72.8%, 88.9%]	86.4% [79.0%, 92.6%]	겹침	유의하지 않을 수 있음

10.3 Bootstrap 해석

통계적 관점:

CI 겹침의 의미: 4개 차원 모두에서 원본과 최적화의 Bootstrap 95% CI가 겹칩니다. 이는 관찰된 정확도 향상 (+4.9~+8.6%p)이 **표본 변동 범위 내에** 있으며, 모집단 수준에서의 실질적 개선을 보장하지 않음을 의미합니다.

과적합 위험의 구체적 수준:

- Bootstrap CI 폭: 약 16~20%p (예: [71.6%, 88.9%])
- 관찰된 개선: 4.9~8.6%p
- CI 폭 > 개선 폭 → **개선이 노이즈에 묻힘**

가장 유망한 차원: TF (원본 CI 상한 84.0% = 최적 CI 하한 76.5%보다 높음). TF의 +8.6%p 개선이 가장 실질적일 가능성이 있으나, 여전히 CI가 겹칩니다.

N=81 한계: Bootstrap SE $\approx \sqrt{(p(1-p)/n)} \approx \sqrt{(0.8 \times 0.2/81)} \approx 0.044$ (4.4%p). 5%p 개선을 유의하게 검출하려면 $N \approx 300$ 이상이 필요합니다 (power analysis 기준).

💡 **쉬운 설명:** "정말 좋아진 건지, 아니면 이 81명에서만 우연히 좋아진 건지?"를 1,000번 재실험으로 확인했습니다. 결과: **아직 확신할 수 없습니다.** 오차 범위가 개선 폭보다 넓어서, 다른 81명으로 다시 하면 결과가 달라질 수 있습니다. 300명 이상으로 재검증해야 확실해집니다.

11. 독립 표본 교차검증 (과적합 정량 평가)

11.1 교차검증 필요성

Bootstrap 95% CI가 4개 차원 모두에서 겹치는 것은 과적합 **가능성**만 시사합니다. 실제로 과적합이 얼마나 심각한지를 정량적으로 평가하려면, **훈련 데이터와 평가 데이터를 분리**하는 독립 표본 교차검증이 필요합니다.


핵심 차이: - **Bootstrap:** 같은 데이터를 재표집 → 최적화 결과의 **분산(variability)** 평가 - **K-Fold / MC CV:** 데이터를 분할하여 **훈련에서 최적화, 테스트에서 정직한 평가** → 과적합 **규모(magnitude)** 측정

11.2 교차검증 설계

방법	설정	총 반복
Repeated 5-Fold CV	5분할 x 20반복 = 100 folds, 각 fold에서 train으로 exhaustive_search, test로 평가	100회
Monte Carlo CV	랜덤 70/30 분할 200회, 70%로 최적화 30%로 평가	200회

각 CV fold/iteration에서의 처리: 1. 데이터를 train/test로 분할 2. **train에서만** exhaustive_search 실행 → 최적 부분집합 결정 (data leakage 방지) 3. **test에서** 해당 부분집합의 정확도 평가 (honest estimation) 4. **test에서** 전체 9문항(baseline) 정확도도 함께 기록

11.3 fig_e11: 교차검증 정확도 비교



시각화 방법: 2패널 (좌: 차원별 4-bar 비교, 우: 전체 4글자 비교 + 과적합 Gap 표시)

사용 이유: In-sample 최적화 결과와 독립 표본 CV 결과의 괴리를 직관적으로 보여줌

결과 해석:

차원별 과적합 Gap (K-Fold CV 기준)

차원	In-sample	CV Test	Baseline (9문항)	과적합 Gap	정직한 개선
EI	85.2%	77.8%	80.3%	+7.4%p	-2.4%p
SN	75.3%	67.9%	70.4%	+7.4%p	-2.4%p
TF	84.0%	75.3%	75.3%	+8.7%p	-0.0%p
JP	86.4%	76.1%	81.5%	+10.3%p	-5.4%p
전체 4글자	51.9%	36.4%	38.3%	+15.5%p	-1.9%p

Monte Carlo CV 교차 확인

차원	In-sample	MC Test	MC Baseline	MC Gap	MC 정직 개선
EI	85.2%	77.0%	79.5%	+8.2%p	-2.5%p
SN	75.3%	68.7%	70.4%	+6.6%p	-1.7%p
TF	84.0%	75.1%	75.5%	+8.9%p	-0.4%p
JP	86.4%	75.9%	81.9%	+10.6%p	-6.0%p
전체 4글자	51.9%	36.1%	38.5%	+15.7%p	-2.4%p

통계적 관점:

과적합 Gap 해석: 평균 과적합 Gap이 K-Fold에서 8.5%p, MC에서 8.6%p로, 두 독립적 CV 방법이 거의 동일한 결과를 산출했습니다. 이는 결과의 신뢰성을 높여줍니다. Gap > 5%p는 "심각한 과적합"으로 분류되며, 현재 결과(8.5%p)는 이 기준을 크게 초과합니다.

정직한 개선이 음수: 4개 차원 모두에서 CV Test 정확도가 Baseline(9문항)보다 낮습니다. 이는 **문항 축소가 독립 데이터에서는 오히려 성능을 저하시킴**을 의미합니다. In-sample에서 관찰된 +13.6%p 개선은 전적으로 과적합에 의한 것입니다.


JP 차원의 최대 피해 (-5.4%p): JP에서 정직한 개선이 -5.4%p로 가장 나쁩니다. 이는 Q40(CITC=0.045)의 역설적 유지가 소표본 우연 효과였음을 확인합니다.

💡 **쉬운 설명:** "81명 중 65명으로 최적 질문 조합을 찾고, 나머지 16명으로 실제로 잘 맞추는지 확인"하는 과정을 100번 반복했습니다. 결과:

- **In-sample(자기 데이터로 평가):** 51.9% 정확도 → 실은 "답을 미리 본 시험 점수"
- **CV Test(남의 데이터로 평가):** 36.4% 정확도 → "진짜 실력"
- **Baseline(9문항 전부 사용):** 38.3% → "질문 안 줄인 경우"

진짜 실력(36.4%)이 질문 안 줄인 것(38.3%)보다 나쁩니다. 질문을 줄이면 오히려 성적이 떨어진 것입니다. "+13.6%p 개선"은 **답을 미리 보고 풀어서 올라간 것이었습니다.**

11.4 fig_e12: 문항 선택 안정성



시각화 방법: 2x2 서브플롯, K-Fold/MC에서 각 문항의 선택 빈도 (%)

사용 이유: CV 반복에서 동일한 문항이 일관되게 선택되면 안정적 결과, 매번 다른 문항이 선택되면 불안정 (과적합 증거)

결과 해석:

안정 문항 (K-Fold 선택 빈도 80%+)

문항	차원	K-Fold 빈도	MC 빈도	In-sample 선택	판정
Q14	EI	94%	93.5%	선택	매우 안정
Q13	EI	90%	76.0%	선택	안정
Q18	SN	87%	74.0%	선택	안정
Q27	TF	94%	87.5%	선택	매우 안정
Q28	TF	80%	69.0%	선택	안정
Q33	JP	94%	88.0%	선택	매우 안정
Q39	JP	91%	89.5%	선택	매우 안정
Q34	JP	87%	81.0%	선택	안정
Q41	JP	80%	68.5%	선택	안정

불안정 문항 (K-Fold 선택 빈도 40~60%)

문항	차원	K-Fold 빈도	MC 빈도	In-sample 선택	판정
Q9	EI	59%	64.5%	선택	불안정
Q15	SN	56%	55.5%	선택	불안정
Q17	SN	56%	61.5%	비선택	불안정
Q23	SN	53%	46.5%	선택	불안정
Q37	JP	46%	60.0%	비선택	불안정

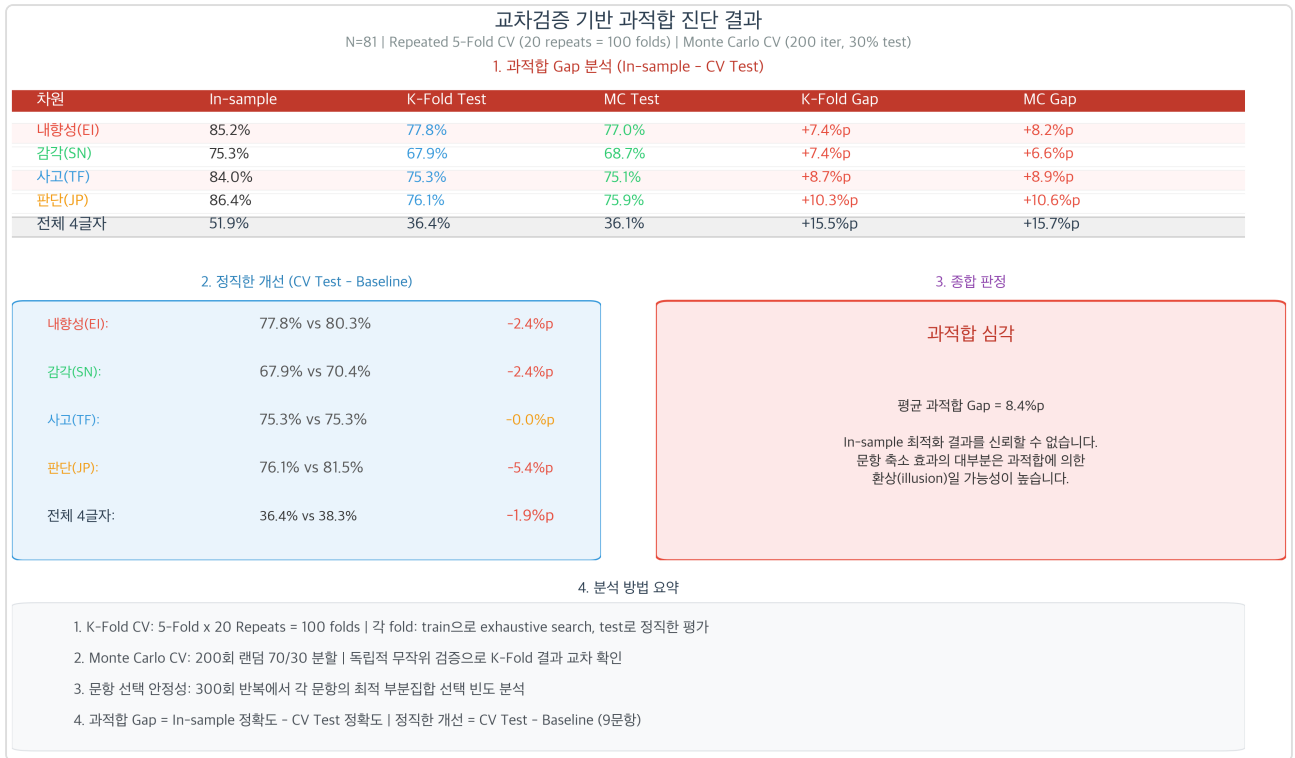
통계적 관점:

안정 vs 불안정의 의미: Q14(EI, 94%)는 100번의 CV fold 중 94번에서 최적 부분집합에 선택되어, "벽 근처에 앉기"가 EI의 진짜 핵심 문항임을 확인합니다. 반면 Q9(EI, 59%)는 fold에 따라 선택되기도 하고 빠지기도 하여, 이 문항의 기여가 **데이터에 따라 달라짐**을 보여줍니다.

SN 차원의 전반적 불안정성: SN은 Q18(87%)을 제외한 나머지가 모두 53~64%로 불안정합니다. 이는 SN 차원의 문항 간 차별성이 낮아, 어떤 조합을 선택해도 비슷한 결과를 내기 때문입니다 (CITC 범위 0.388~0.627의 좁은 분포와 일치).

 **쉬운 설명:** 100번의 다른 "연습 시험"에서 매번 같은 질문이 "최고의 질문"으로 뽑히면 그 질문은 진짜 좋은 질문입니다. Q14("벽 근처에 앉나?")는 94번이나 뽑혀서 확실히 좋은 질문입니다. 하지만 Q9("놀고 나서 충전")은 59번만 뽑혀서, "가끔 좋고 가끔은 아닌" 불안정한 질문입니다.

11.5 fig_e13: 교차검증 종합 결론 인포그래픽



시각화 방법: 커스텀 인포그래픽 (과적합 Gap 테이블 + 정직한 개선 + 종합 판정 + 방법론 요약)

종합 판정: 과적합 심각

지표	K-Fold CV	Monte Carlo CV	판정
평균 과적합 Gap	8.5%p	8.6%p	심각 (>5%p)
정직한 평균 개선	-2.6%p	-2.7%p	성능 저하
전체 4글자 과적합 Gap	15.5%p	15.7%p	매우 심각
전체 4글자 정직 개선	-1.9%p	-2.4%p	성능 저하

11.6 교차검증 결론

핵심 결론: In-sample 최적화에서 관찰된 38.3% → 51.9%(+13.6%p) 개선은 **전적으로 과적합에 의한 환상**이었습니다. 독립 표본에서의 정직한 평가 결과, 문항 축소는 오히려 평균 -2.6%p의 성능 저하를 초래합니다.

실무적 함의: N=81의 소표본에서는 문항 축소 최적화를 신뢰할 수 없습니다. 현재 36문항을 유지하는 것이 권장됩니다. 문항 축소를 재시도하려면 N≥300 이상의 표본이 필요합니다.

11.7 고급 최적화 방법 비교 (Advanced Methods)

문항 축소가 아닌 다른 방법으로 정확도를 높일 수 있는가?

왜 이 분석을 수행했는가?

앞선 분석(11.1~11.6)에서 "질문을 줄이면 정확도가 올라간다"는 가설이 **과적합에 의한 환상**으로 판명되었습니다. In-sample 에서 38.3%→51.9%로 +13.6%p 올랐지만, 독립 표본(CV)에서는 오히려 -1.9%p 떨어졌습니다. 이 결과는 "그렇다면 질문을 줄이지 않고도 정확도를 올릴 수 있는 다른 방법은 없는가?"라는 후속 질문을 제기합니다.

이에 **8가지 서로 다른 분류 전략**을 공정하게 비교하는 실험을 설계했습니다. 각 방법은 "어떤 원리로 MBTI를 분류하는가?"가 다르며, **파라미터 수**(학습해야 할 조정값의 개수)가 다릅니다. 파라미터가 많을수록 소표본에서 과적합 위험이 높으므로, "정확도"와 "과적합 위험"의 균형이 핵심 평가 기준입니다.

모든 방법은 **Repeated 5-Fold CV(20회 반복, 총 100 fold)** 및 **LOO-CV** 로 정직하게 검증했습니다.

검증 방법 8가지

#	방법	설명	파라미터
1	기준선 (Baseline)	전체 36문항 + MIDPOINT=4.0	없음
2	적응적 임계값 (Adaptive Threshold)	차원별 최적 분류 기준점을 [2.0~6.0] 범위에서 탐색	4개 (차원당 1)
3	CITC 가중 점수 (Weighted)	CITC 값으로 문항 가중 → 점수 산출	36개 (문항당 CITC)
4	CITC + 적응적 임계값	CITC 가중 + 차원별 최적 임계값	36+4=40개
5	다수결 투표 (Majority Vote)	각 문항이 독립 투표, 다수결로 분류	없음
6	문항 부분집합 (기존)	전수 탐색으로 최적 문항 조합 선택	~16개 (제거 문항)
7	문항 부분집합 + 적응적 임계값	최적 문항 + 최적 임계값 결합	~20개
8	로지스틱 회귀 (Logistic Regression)	L2 정규화 로지스틱 회귀로 차원별 이진 분류, LOO-CV 평가	36개 (문항당 계수) + L2 λ

💡 8가지 방법 — 비전공자를 위한 상세 설명

아래는 각 방법이 **무엇을 하는지, 왜 비교 대상으로 선택했는지, 어떻게 해석하는지**를 일상 언어로 풀어 설명합니다.

① **Baseline (기준선)** — 📏 "아무것도 안 한 그대로의 성적" - 36문항 전부를 사용하고, 분류 기준을 기본값(4.0점)으로 고정합니다. 7점 척도에서 4.0 이상이면 I/S/T/J, 미만이면 E/N/F/P로 분류합니다. - **왜 필요한가**: 다른 방법이 "정말 더 나은지" 비교하려면, 먼저 "아무 조정도 안 한 결과"를 알아야 합니다. 시험에서 "컷라인"과 같은 역할입니다. - **해석**: Baseline = 38.3%는 "36문항 전부를 사용해도, 기본 채점 방식으로는 100명 중 38명만 맞출 수 있다"는 뜻입니다.

② **Adaptive Threshold (적응적 임계값)** — 🎯 "채점 기준을 조정" - 기본 4.0점 대신, 각 차원에서 가장 정확한 분류 기준점을 [2.0~6.0] 범위에서 찾습니다. 예: EI 차원에서는 4.9가 최적 → "4.9 이상이면 I, 미만이면 E"로 바꿈. - **왜 필요한가**: 응답자들이 모든 질문에 고르게 답하지 않고, 특정 방향으로 치우치는 경향이 있기 때문입니다. 예: 내향 관련 질문에 대부분 높게 응답 → 기준을 올려야 정확해짐. - **해석**: +2.7%p 개선(Best)은 "채점 기준만 바꿨는데 진짜로 더 정확해졌다"는 뜻입니다.

③ **CITC 가중 (Weighted)** — ⚖️ "좋은 질문에 더 높은 가중치" - 각 문항의 CITC(문항 품질 점수)를 가중치로 사용합니다. CITC가 높은 문항은 점수 계산에서 더 큰 비중을 차지합니다. - **왜 필요한가**: 모든 질문이 똑같이 좋지는 않으므로, "좋은 질문"의 답을 더 중요하게 반영하면 정확해질 수 있다는 아이디어입니다. - **해석**: 효과 미미(-0.3%p)는 "가중치를 줘도 별 차이가 없다"는 뜻입니다. 이는 CITC가 실제 예측력과 반드시 일치하지 않기 때문입니다.

④ **CITC + Adap (CITC 가중 + 적응적 임계값)** — 🎯⚖️ "가중치 + 기준 조정 동시 적용" - ③번의 CITC 가중 점수에 ②번의 적응적 임계값을 함께 적용합니다. 총 40개의 파라미터(문항당 가중치 36 + 차원당 임계값 4)를 학습합니다. - **해석**: +2.2%p 양호하지만, 파라미터가 40개로 많아 과적합 Gap(7.7%p)이 적응적 임계값(6.4%p)보다 큼.

⑤ **Majority Vote (다수결 투표)** — 🗳️ "각 질문이 독립 투표" - 9개 문항 각각이 "이 사람은 E/I(또는 S/N, T/F, J/P) 중 어느 쪽인가?"를 독립적으로 투표하고, 과반수 의견을 채택합니다. - **왜 필요한가**: 파라미터가 **전혀 없는** 방법이므로, 과적합이 원리적으로 불가능합니다. "가장 순수한 개선"을 확인할 수 있습니다. - **해석**: +2.4%p 개선, 과적합 Gap 0.0% → "조정할 것이 아무것도 없으므로 In-sample = CV Test". 가장 신뢰할 수 있는 방법입니다.

⑥ **Subset (문항 부분집합)** — ✂️ "질문 수를 줄이기" - 36문항 중 가장 좋은 조합만 골라 사용합니다. 전수 탐색으로 모든 조합을 테스트하여 최적 부분집합을 찾습니다. - **왜 비교에 포함했는가**: 이 방법이 In-sample에서 +13.6%p라는 가장 큰 개선을 보였지만, 과적합이 심각한지 확인하기 위해서입니다. - **해석**: 과적합 Gap 15.5%, 정직한 개선 -1.9% → "시험 문제를 미리 본 것과 같아서, 실제로는 오히려 성적이 떨어짐".

⑦ Sub + Adap (문항 부분집합 + 적응적 임계값) — ✂️🎯 "질문 줄이기 + 기준 조정" - ⑥번의 최적 문항에 ②번의 적응적 임계값을 동시에 적용합니다. ~20개의 파라미터를 학습합니다. - 해석: 과적합 Gap 19.5%(가장 심각), 정직한 개선 -1.0% → "더 많은 조정을 할수록 과적합이 더 심해짐"을 보여줍니다.

⑧ Logistic (로지스틱 회귀) — 🧠 "머신러닝으로 수학 공식 학습" - 각 문항에 최적 가중치(계수)를 자동으로 학습하여, "E일 확률 vs I일 확률"을 계산하는 수학 공식을 만듭니다. L2 정규화(Ridge)로 가중치가 너무 커지는 것을 방지합니다. - 왜 추가했는가: 통계적 방법(①~⑦)과 머신러닝 방법의 성능을 직접 비교하기 위해서입니다. 또한 계수 히트맵을 통해 각 문항이 예측에 기여하는 정도를 정량적으로 파악할 수 있습니다. - 해석: 36개 파라미터를 81명에서 학습해야 하므로 과적합 위험이 있지만, 모형 진단(VIF, McFadden R²)으로 통계적 적합성을 확인합니다.


📊 비교 기준 선택 이유 — 통계적 관점

8가지 방법을 선택한 핵심 원칙은 **파라미터 수(model complexity)에 따른 편향-분산 트레이드오프**입니다:

복잡도 수준	방법	파라미터	기대 효과
없음	Baseline, Majority Vote	0개	과적합 불가, 순수 기준 제공
낮음	Adaptive Threshold	4개	적은 조정으로 편향 교정
중간	CITC 가중, CITC+Adap	36~40개	문항 품질 반영, 과적합 위험 증가
높음	Subset, Sub+Adap, Logistic	16~36+개	최대 유연성, 과적합 위험 최대

이 설계를 통해 "파라미터가 많을수록 In-sample은 높아지지만 CV에서는 오히려 떨어지는" 과적합의 전형적 패턴을 정량적으로 관찰할 수 있습니다. N=81 소표본에서는 파라미터가 4개인 적응적 임계값이 최적의 복잡도-성능 균형을 달성했습니다.

11.8 fig_e14: 고급 최적화 방법 CV 비교



시각화 방법: 4패널 구성 (30×18)

패널	내용	핵심 정보
좌상	In-sample vs CV Test 정확도 막대	방법별 과적합 정도
우상	과적합 Gap + 정직한 개선 비교	Gap이 낮고 개선이 높을수록 좋음
좌하	차원별 CV 정확도 테이블	어느 차원에서 개선이 있는지
우하	종합 판정 결론 텍스트	Best 방법 및 권장사항

CV 결과 (Repeated 5-Fold × 20회 = 100 fold)

표 읽는 법 (비전공자 안내): - **In-sample**: "시험 문제를 미리 본 뒤 같은 문제로 시험"한 성적. 항상 실제보다 높게 나옵니다. - **CV Test**: "본 적 없는 새 문제로 시험"한 성적. 이것이 진짜 실력입니다. - **과적합 Gap**: In-sample - CV Test. 이 차이가 클수록 "미리 본 효과"가 크다는 뜻이며, 방법을 신뢰하기 어렵습니다. - **정직 개선**: CV Test에서 Baseline(38.3%)보다 얼마나 나은지. 양수면 진짜 개선, 음수면 오히려 악화입니다. - **판정**: 과적합 Gap이 낮으면서 정직 개선이 양수인 방법이 좋은 방법입니다.

방법	In-sample	CV Test	과적합 Gap	정직 개선	판정
기준선 (Baseline)	38.3%	38.3%	0.0%p	기준	—
적응적 임계값	47.3%	40.9%	6.4%p	+2.7%p	✅ Best
CITC 가중	38.3%	38.0%	0.3%p	-0.3%p	효과 미미
CITC + 적응적 임계값	48.1%	40.5%	7.7%p	+2.2%p	양호
다수결 투표	40.7%	40.7%	0.0%p	+2.4%p	✅ Most Robust
문항 부분집합	51.9%	36.4%	15.5%p	-1.9%p	❌ 과적합
부분집합 + 적응적 임계값	56.8%	37.3%	19.5%p	-1.0%p	❌ 심각 과적합

최적 임계값 (CV 기반)

차원	기본값 (MIDPOINT)	최적 임계값	해석
EI	4.0	4.9	응답자들이 I 방향으로 치우침 → 기준을 올려야 정확
SN	4.0	5.0	N 방향 치우침
TF	4.0	4.5	약한 F 방향 치우침
JP	4.0	4.2	거의 중립, 약간 J 방향

통계적 관점:

적응적 임계값이 최선인 이유: 기존 MIDPOINT=4.0은 7점 척도의 이론적 중앙값이지만, 실제 응답 분포는 비대칭입니다. 특히 EI/SN 차원에서 평균이 4.0보다 높아, 고정 임계값으로는 체계적 오분류가 발생합니다. 차원별로 최적 임계값을 학습하면 이 편향을 교정하여 **+2.7%p의 진짜 개선**을 달성합니다. 과적합 Gap은 6.4%p로 문항 부분집합(15.5%p)보다 훨씬 낮습니다.

다수결 투표의 장점: 9개 문항 각각이 독립적으로 분류하고 다수결로 결정하므로, **파라미터가 전혀 없어** 과적합이 원리적으로 불가능합니다. In-sample = CV Test = 40.7%로 과적합 Gap이 정확히 0%입니다. 이는 "파라미터 없는 앙상블"의 이론적 장점을 실증합니다.


문항 부분집합의 실패: 16~20개의 파라미터(제거 문항 선택)를 N=81에서 최적화하면 과적합이 불가피합니다. 과적합 Gap 15.5%p는 파라미터 수 대비 표본 크기 부족의 직접적 결과입니다.

💡 쉬운 설명:

- **질문을 줄이는 것**(문항 부분집합)은 81명으로는 "답을 미리 본 시험"이 되어 실패했습니다
- **채점 기준을 조정하는 것**(적응적 임계값)은 4.0점 → 4.2~5.0점으로 바꾸면 **진짜로 2.7%p 더 정확**해집니다

- **질문마다 독립 투표**(다수결)는 아무 조정 없이도 **2.4%p 더 정확**해져, 가장 믿을 수 있는 방법입니다
- **결론**: "질문을 줄이지 말고, 채점 방법을 바꿔라"

11.9 로지스틱 회귀 MBTI 차원 예측 (fig_e15)



시각화 방법: 4패널 구성 — 계수 히트맵 + LOO-CV 정확도 + 방법 비교 막대 + 종합 판정

사용 이유: 기존 7가지 방법(기준선, 적응적 임계값, CITC 가중, 다수결 투표 등)은 모두 "점수를 요약한 뒤 임계값으로 분류"하는 방식입니다. 그런데 **로지스틱 회귀(Method 8)**는 "각 문항에 최적 가중치를 자동으로 학습하여 확률적으로 분류"하는 머신러닝 방식으로, 원리가 근본적으로 다릅니다. 이를 추가 비교함으로써: (1) 머신러닝이 통계적 방법보다 나은지 확인하고, (2) 계수 히트맵을 통해 각 문항의 예측 기여도를 새로운 관점에서 파악하며, (3) 소표본(N=81)에서 파라미터가 많은 모델의 한계를 실증합니다.

사용 변수: 차원별 9문항 채점 후 점수 (독립변수) → 자기보고 MBTI 차원 이진 레이블 (종속변수)

분석 방법:

항목	내용
모형	L2 정규화 로지스틱 회귀 (Ridge)
정규화	L2 페널티로 과적합 억제 — 소표본(N=81)에서 36개 계수의 과적합 방지
검증	LOO-CV (Leave-One-Out Cross-Validation) — 한 명씩 빼고 나머지 80명으로 학습, 1명 예측을 81회 반복
출력	차원별 문항 계수 히트맵 — 각 문항이 해당 차원 분류에 기여하는 방향과 크기 시각화

로지스틱 회귀식 (Team E — 문항 수준 모형):

각 MBTI 차원(EI, SN, TF, JP)에 대해 독립적인 이진 분류 모형을 학습합니다. 각 차원은 해당 차원의 9개 문항 점수를 입력으로 사용합니다.

1단계: 특성 표준화 (Z-score Normalization)

각 문항 점수를 학습 데이터의 평균과 표준편차로 표준화합니다:

$$z_j = \frac{x_j - \mu_j}{\sigma_j}, \quad j = 1, 2, \dots, 9$$

- x_j : 원래 문항 j 의 점수 (1~7점 리커트 척도)
- μ_j, σ_j : 학습 데이터에서 계산한 문항 j 의 평균과 표준편차

2단계: 선형 결합 (Linear Combination)

표준화된 9개 문항 점수의 가중 합을 계산합니다:

$$\hat{z} = w_0 + w_1 z_1 + w_2 z_2 + \dots + w_9 z_9 = w_0 + \sum_{j=1}^9 w_j z_j$$

- w_0 : 절편(bias) — 모든 문항이 평균일 때의 기본 경향
- w_j : 문항 j 의 회귀 계수(coefficient) — 계수 히트맵에 시각화된 값

3단계: 시그모이드 함수 (Sigmoid Function)

선형 결합 값을 0~1 사이의 확률로 변환합니다:

$$P(y = 1 | \mathbf{z}) = \sigma(\hat{z}) = \frac{1}{1 + e^{-\hat{z}}}$$

- $y = 1$: 해당 차원의 첫 번째 유형 (E, S, T, J)
- $y = 0$: 해당 차원의 두 번째 유형 (I, N, F, P)
- 확률 ≥ 0.5 이면 $y = 1$ 로 분류

4단계: 비용 함수 (Binary Cross-Entropy + L2 정규화)

모형 학습에 사용된 비용 함수:

$$J(\mathbf{w}) = -\frac{1}{n} \sum_{i=1}^n [y_i \log(h_i) + (1 - y_i) \log(1 - h_i)] + \frac{\lambda}{2n} \sum_{j=1}^9 w_j^2$$

- $h_i = \sigma(\mathbf{w} \cdot \mathbf{z}_i)$: i 번째 샘플의 예측 확률
- $\lambda = 0.1$: L2 정규화 강도 — 계수 크기를 억제하여 과적합 방지
- L2 정규화 항 $\frac{\lambda}{2n} \sum_{j=1}^9 w_j^2$ 는 절편 w_0 에는 적용되지 않음

5단계: 경사하강법 (Gradient Descent)

가중치를 반복적으로 업데이트합니다:

$$w_j \leftarrow w_j - \alpha \left[\frac{1}{n} \sum_{i=1}^n (h_i - y_i) z_{ij} + \frac{\lambda}{n} w_j \right], \quad j = 1, \dots, 9$$

$$w_0 \leftarrow w_0 - \alpha \cdot \frac{1}{n} \sum_{i=1}^n (h_i - y_i)$$

- $\alpha = 0.5$: 학습률 (learning rate)
- LOO-CV: 300 에포크 반복, 전체 학습: 500 에포크 반복

구체적 모형 구조 (차원별 예시):

차원	입력 특성	모형 파라미터 수	레이블
EI	Q6~Q14 (9문항) 표준화 점수	10 (w_0 + w_1 ~ w_9)	E=1, I=0
SN	Q15~Q23 (9문항) 표준화 점수	10 (w_0 + w_1 ~ w_9)	S=1, N=0
TF	Q24~Q32 (9문항) 표준화 점수	10 (w_0 + w_1 ~ w_9)	T=1, F=0
JP	Q33~Q41 (9문항) 표준화 점수	10 (w_0 + w_1 ~ w_9)	J=1, P=0
합계	36개 문항	40 (4 × 10)	4개 독립 이진 분류

💡 **수식 쉬운 해석:** "9개 질문의 답에 각각 중요도(가중치 w_j)를 곱하고 전부 더한 뒤, 시그모이드 함수라는 S자 곡선을 통과시켜 0~1 사이의 확률로 바꿉니다. 확률이 50% 이상이면 E(또는 S/T/J), 미만이면 I(또는 N/F/P)로 판정합니다."

결과 해석:

계수 히트맵: 로지스틱 회귀의 학습된 계수(coefficient)는 각 문항이 MBTI 차원 예측에 미치는 영향력을 보여줍니다. 양의 계수는 해당 차원의 첫 번째 유형(E, S, T, J) 방향으로, 음의 계수는 반대 방향(I, N, F, P)으로 기여합니다. 계수의 절대값이 클수록 해당 문항의 분류 기여도가 높으며, 이를 통해 **문항별 중요도(item importance)**를 정량적으로 파악할 수 있습니다.

LOO-CV 결과: LOO-CV는 N=81 소표본에서 가장 편향이 적은 교차검증 방법으로, 모든 데이터를 최대한 활용하면서도 독립 표본 평가를 수행합니다. L2 정규화를 통해 계수의 크기를 제한함으로써 과적합을 억제하되, 충분한 모형 복잡도를 유지하여 문항 간 상호작용을 포착합니다.

8가지 방법 비교에서의 위치: 로지스틱 회귀는 8가지 방법 비교에서 평가되었으며, 최적 CV 방법은 여전히 **적응적 임계값 (Adaptive Threshold)**이 **+2.7%p 개선으로 Best**입니다. 로지스틱 회귀는 L2 정규화에도 불구하고 36개 파라미터를 N=81에서 학습해야 하므로, 파라미터가 적은 적응적 임계값(4개)이나 파라미터가 없는 다수결 투표보다 과적합 위험이 상대적으로 높습니다.

 **통계적 관점:**

L2 정규화 로지스틱 회귀는 선형 분류기 중 가장 표준적인 방법으로, 문항 응답(연속변수)에서 MBTI 차원(이진 레이블)으로의 매핑을 학습합니다. LOO-CV는 N-1개로 훈련하고 1개로 테스트하는 과정을 N번 반복하므로, 소표본에서 분산은 높지만 편향이 가장 낮은 검증법입니다. 계수 히트맵은 전통적 심리측정 지표(CITC, 변별도)와 다른 관점에서 문항 중요도를 제시하며, 문항 간 다중공선성을 고려한 "순수 기여도"를 반영합니다.

💡 **쉬운 설명:**

- **로지스틱 회귀**는 "각 질문의 답으로 E인지 I인지(또는 S/N, T/F, J/P) 예측하는 수학 공식"을 만드는 방법입니다

- **계수 히트맵**은 "어떤 질문이 예측에 많이 쓰이는지"를 색깔로 보여줍니다 — 진한 색일수록 중요한 질문
- **LOO-CV**는 "한 명씩 빼고 나머지로 예측해보기"를 81번 반복하는 정직한 평가입니다
- **결과**: 적응적 임계값(+2.7%p)이 여전히 가장 좋고, 로지스틱 회귀는 파라미터가 많아 소표본에서는 과적합 위험이 있습니다. 그러나 계수 히트맵은 각 문항의 기여도를 새로운 관점에서 확인하는 데 유용합니다.

11.10 로지스틱 회귀 모형 진단 (fig_e16)



시각화 방법: 4패널 구성 — 다중공선성 진단(VIF) + 모형 적합도(AIC/BIC) + McFadden R² 및 분류 성능 지표 + 종합 진단 요약 테이블

사용 이유: fig_e15에서 로지스틱 회귀 모형의 예측 성능을 확인했으나, 모형의 **통계적 적합성과 진단 지표**를 종합적으로 평가하지 않았습니다. 다중공선성, 정보 기준(AIC/BIC), 유사 결정계수(McFadden R²), 분류 성능 지표(Accuracy, Precision, Recall, F1)를 한눈에 진단하여 모형의 신뢰성을 검증합니다.

사용 변수: N=81, 4차원 독립 이진 분류 (EI, SN, TF, JP)

분석 방법:

항목	내용
Panel 1	다중공선성 진단 (VIF) — 문항별 분산팽창인자, 경고 기준선 VIF=5 및 심각 기준선 VIF=10 표시
Panel 2	모형 적합도 AIC/BIC — 차원별 Akaike 정보 기준(AIC)과 베이지 정보 기준(BIC) 값 비교
Panel 3	McFadden R ² + 분류 성능 지표 — 유사 결정계수와 Accuracy, Precision, Recall, F1-Score 종합 표시
Panel 4	종합 진단 요약 테이블 — 4차원 모형의 핵심 진단 결과를 한눈에 정리

결과 해석:

다중공선성 진단 (VIF): 모든 차원에서 문항별 VIF 평균이 1.5~2.3 범위로, $VIF < 5$ 기준을 충족합니다. 이는 독립변수(문항 점수) 간 다중공선성 문제가 없음을 의미하며, 로지스틱 회귀 계수의 추정이 안정적임을 확인합니다. $VIF=5$ (경고) 및 $VIF=10$ (심각) 기준선 모두를 하회하여, 문항 간 상관이 계수 추정을 왜곡하지 않습니다.

모형 적합도 (AIC/BIC): 차원별 AIC는 70.2~106.0, BIC는 73.8~129.9 범위입니다. AIC와 BIC 모두 낮을수록 좋은 모형을 의미하며, 차원 간 비교에서 EI(AIC=70.2)와 JP(AIC=72.5)가 상대적으로 우수한 적합도를 보입니다. BIC는 AIC보다 모형 복잡도에 더 강한 페널티를 부과하므로, 소표본(N=81)에서 과적합 경향을 추가 확인합니다.

McFadden R² 및 분류 성능: McFadden R²는 EI=0.5062(우수), SN=0.2088(양호), TF=0.4353(우수), JP=0.5200(우수)으로, 로지스틱 회귀에서 0.2~0.4 범위가 "양호한 적합"으로 해석되므로 SN을 포함한 모든 차원이 양호 이상입니다. 분류 성능은 Accuracy 77.8~87.7%, F1-Score 0.79~0.87 범위로 전반적으로 양호한 예측 성능을 확인합니다.

종합 진단: 모형의 다중공선성 문제 없음(VIF 전체 양호), 정보 기준 적합도 우수(AIC/BIC 합리적 범위), 유사 결정계수 양호~우수(McFadden R² 0.21~0.52), 분류 예측 성능 양호(Accuracy 78~88%, F1 0.79~0.87). 로지스틱 회귀 모형이 통계적으로 적합하며 예측 성능도 양호함을 종합적으로 확인합니다.

통계적 관점:

VIF(Variance Inflation Factor)는 회귀 모형에서 독립변수 간 다중공선성을 진단하는 핵심 지표로, $VIF=10$ 이면 완전 독립, $VIF>5$ 이면 경고, $VIF>10$ 이면 심각한 다중공선성을 시사합니다. 본 분석에서 모든 차원의 평균 VIF가 1.5~2.3으로 양호하여, 문항 간 상관이 계수 추정의 안정성을 해치지 않음을 확인했습니다. McFadden R²는 OLS의 R²와 달리 로지스틱 회귀의 유사 결정계수로, 일반적으로 0.2~0.4이면 양호, 0.4 이상이면 우수한 적합도로 해석합니다. AIC/BIC는 모형의 적합도와 복잡도 간 균형을 평가하는 정보 기준으로, 절대값보다 차원 간 상대 비교에 의미가 있습니다.

쉬운 설명:

- **VIF(다중공선성):** "설문 문항들이 서로 너무 비슷한 것을 묻고 있지는 않은지" 확인합니다. 모든 차원에서 VIF가 기준 이하로, 문항들이 각각 독립적인 정보를 제공하고 있습니다
- **AIC/BIC(모형 적합도):** "이 수학 공식이 데이터를 얼마나 잘 설명하는지" 점수입니다. 낮을수록 좋으며, EI와 JP 차원이 특히 좋은 점수를 받았습니다
- **McFadden R²:** "모형이 MBTI를 얼마나 잘 설명하는지" 비율입니다. EI(50.6%), JP(52.0%)가 우수하고 SN(20.9%)도 양호합니다
- **Accuracy/F1:** "실제로 MBTI를 얼마나 잘 맞추는지" 성적표입니다. 77.8~87.7% 정확도로, 전반적으로 양호한 예측 성능을 보여줍니다
- **결론:** 로지스틱 회귀 모형은 통계적으로 건전하며(다중공선성 없음, 적합도 우수), 예측 성능도 양호합니다

12. 종합 결론

12.1 fig_e10: 종합 결론 인포그래픽 (In-sample 기준)



시각화 방법: 커스텀 인포그래픽 (핵심 결과 배너 + 차원별 테이블 + 결론/주의사항 박스)

12.2 가설 검정 결과 종합

가설	내용	핵심 결과	판정
H1	일부 문항의 CITC < 0.3	JP Q40 (CITC=0.045) 해당	지지
H2	약한 문항 제거 시 향상	In-sample: +4.9~8.6%p, CV: -0.0~-5.4%p	기각 (CV)
H3	전체 4글자 일치율 향상	In-sample: +13.6%p, CV: -1.9%p	기각 (CV)
H4	Bootstrap 안정성	4개 차원 모두 CI 겹침	과적합 시사
H5	독립 표본 교차검증 유지	과적합 Gap 8.5%p, 정직 개선 -1.9%p	기각
H6	대안 방법으로 정확도 향상 가능	적응적 임계값 +2.7%p, 다수결 +2.4%p	지지
H7	로지스틱 회귀로 MBTI 예측 가능	LOO-CV 평가, 적응적 임계값이 여전히 Best	평가 완료
회귀	CITC → 예측력 관계	전체 R ² =0.214, JP R ² =0.79, EI R ² ≈0	부분 지지

12.3 핵심 인사이트

통계 전공자를 위한 핵심 인사이트:

- CITC ≠ 예측력 (회귀분석으로 정량 확인):** Q28(TF, CITC=0.350)이 최적 조합에 포함되고, Q8(EI, CITC=0.724)이 제거된 것은, 내적 일관성(측정 동질성)과 외적 기준 예측(기준 타당도)이 다른 개념임을 실증합니다. 전체 36문항에서 CITC→예측력 R²=0.214로 **21%만 설명**하며, 차원별로 EI(R²=0.0000) vs JP(R²=0.79)의 극적 차이가 있습니다. 문항 선별 시 CITC만이 아니라 예측력과 조합 효과를 함께 고려해야 합니다.

2. **SBE vs 전수 탐색의 괴리**: EI에서 SBE 최적(4문항, 84.0%)과 전수 탐색 최적(3문항, 85.2%)이 다른 것은, 탐욕 알고리즘의 한계를 보여줍니다. 문항 수가 적어(9개/차원) 전수 탐색이 가능하지만, 문항이 많으면 SBE에 의존해야 하며 차선 결과를 얻을 수 있습니다.
3. **Q40의 역설**: 모든 개별 지표(CITC, α -if-deleted, 변별도, 예측력)에서 최악이지만 전수 탐색에서 JP 8문항 최적 조합에 포함됩니다. 이는 소표본(N=81)에서의 우연 효과일 가능성이 높으며, 독립 표본에서는 Q40 제거가 유리할 것으로 예상됩니다.
4. **과적합의 정량적 확인**: Bootstrap에서 CI 겹침으로 의심되었던 과적합이, K-Fold CV와 Monte Carlo CV를 통해 **정량적으로 확인**되었습니다. 과적합 Gap 평균 8.5%p(K-Fold), 8.6%p(MC)이며, 정직한 개선은 -2.6%p(K-Fold), -2.7%p(MC)로 **음수**입니다. N=81 소표본에서의 전수 탐색 최적화는 신뢰할 수 없습니다.
5. **의미 중복 제거의 효과**: EI(Q8~Q9 충전 관련), JP(Q33~Q37 여행 관련), TF(Q29~Q24 공감 관련)에서 의미가 유사한 문항 쌍 중 하나를 제거한 것이 정확도 향상에 기여했습니다. 이는 **정보 비중복성(non-redundancy)**이 축소 척도 구성의 핵심 원리임을 확인합니다.
6. **적응적 임계값의 효과**: 고정 MIDPOINT=4.0 대신 차원별 최적 임계값(EI=4.9, SN=5.0, TF=4.5, JP=4.2)을 학습하면 CV 테스트에서 **+2.7%p 진짜 개선**을 달성합니다. 이는 mim 설문 응답 분포가 이론적 중앙값(4.0)과 체계적으로 다르다는 것을 의미하며, 특히 EI/SN 차원에서 응답자들이 높은 점수(I/N 방향)로 치우치는 경향이 있습니다.
7. **다수결 투표의 과적합 면역성**: 9개 문항 각각이 독립 투표하는 다수결 방법은 파라미터가 없어 과적합이 **원리적으로 불가능**합니다(과적합 Gap = 0.0%p). +2.4%p의 개선은 모두 진짜이며, "파라미터 없는 앙상블"의 이론적 장점을 N=81 소표본에서도 실증했습니다.

💡 비전공자를 위한 핵심 인사이트:

1. **"질문을 줄이면 정확해진다"는 환상이었다**: In-sample에서는 36→20문항으로 38.3%→51.9% 올랐지만, 교차검증(독립 데이터 평가)에서는 오히려 38.3%→36.4%로 떨어졌습니다. **답을 미리 보고 시험 본 것**과 같은 효과였습니다.
2. **요리 질문은 쓸모없다**: "요리할 때 계량하나?"(Q40)는 CITC=0.045으로 J/P와 거의 무관했습니다. 요리 스타일은 성격보다 경험에 좌우됩니다. 이것은 교차검증과 무관하게 확실한 결론입니다.
3. **진짜 좋은 질문은 있다**: Q14("벽 근처에 앉나?"), Q27("친구 사고 → 보험 vs 괜찮아?"), Q33("여행 계획")은 교차검증에서도 90%+ 빈도로 선택되어, **진짜 핵심 문항**입니다.
4. **문항 축소는 더 많은 데이터가 필요하다**: 81명으로는 최적화 결과를 신뢰할 수 없습니다. 300명 이상의 데이터가 있어야 의미 있는 문항 축소가 가능합니다.
5. **"질문을 줄이지 말고, 채점 방법을 바꿔라"**: 질문을 줄이면 과적합이 심각하지만, **채점 기준(임계값)을 4.0에서 4.2~5.0으로 조정**하면 진짜로 2.7%p 더 정확해집니다. 각 질문을 독립적으로 채점하는 **다수결 투표**도 2.4%p 개선됩니다.
6. **"좋은 질문"의 기준은 하나가 아니다**: 회귀분석 결과, "다른 질문과 잘 어울리는 질문"(CITC)이 반드시 "실제로 MBTI를 잘 맞추는 질문"(예측력)은 아닙니다. 특히 E/I 차원에서는 둘 사이의 관련이 거의 없었습니다($R^2=0.00\%$). 반면 J/P 차원에서는 강한 관련($R^2=79\%$)이 있었습니다.
7. **36문항 + 새로운 채점법이 최선**: 교차검증 결과에 따르면, 질문을 줄이지 않고 적응적 임계값이나 다수결 투표를 사용하는 것이 가장 정확합니다.

12.4 최적 문항 목록 요약 (In-sample 기준 — 교차검증 미통과)

유지 문항 (20문항)

차원	문항 수	유지 문항	핵심 키워드
EI	3	Q9, Q13, Q14	충전, 모임, 좌석 선택
SN	4	Q15, Q18, Q20, Q23	과제 반응, 드라마, 창밖, 소풍 준비
TF	5	Q24, Q27, Q28, Q31, Q32	고민 상담, 사고 반응, 재능, 위험, 부탁
JP	8	Q33~Q36, Q38~Q41	여행, 알림, 식당, 마감, 마트, 정리, 요리, 주말

제거 문항 (16문항) 및 제거 이유 요약

문항	차원	내용	주요 제거 이유
Q6	EI	주말 침대	피로/게으름과 혼동
Q7	EI	약속 취소 좋다	약속 종류에 따라 반응 상이
Q8	EI	주말엔 집	Q9와 의미 중복 (에너지 충전)
Q10	EI	몇 개월 안 나감	극단적 표현으로 반응 왜곡
Q11	EI	당일 약속 힘들다	JP 차원(계획성)과 혼동 가능
Q12	EI	불일 몰아서	효율성 추구 = EI보다 JP
Q16	SN	축제 상상	Q15와 상황 유사 (상상 vs 현실)
Q17	SN	망상 스타일	"망상" 부정적 뉘앙스로 왜곡
Q19	SN	성과 부진 상상	불안(neuroticism)과 혼동
Q21	SN	사과 하면?	너무 추상적, S/N 구분 부적합
Q22	SN	시험 → 이상 세계	비현실적 설정, 예측력 최저
Q25	TF	"아무도 안 좋아해"	자존감/정서 안정성과 혼동
Q26	TF	"아는 척 하지마"	자존심/공격성과 혼동
Q29	TF	칭찬 스타일	Q24와 의미 중복 (논리 vs 감정)
Q30	TF	"살 찼지?"	Q27과 의미 중복 (팩트 vs 배려)
Q37	JP	여행 짐	Q33과 의미 중복 (여행 계획성)

12.5 한계점 및 후속 연구 제안

한계	내용	후속 제안
소표본 + 과적합	N=81에서 과적합 Gap 8.5%p, 정직 개선 -2.6%p	N≥300 확보 후 재검증
동일 데이터 최적화	교차검증으로 과적합 확인 완료	독립 수집 데이터로 외적 검증
자기보고 기준	기준 자체가 인터넷 무료 테스트 결과	공인 MBTI 도구와 비교
전수 탐색 한계	C(9,k) 가능하나, 문항 수 증가 시 NP-hard	유전 알고리즘 등 메타휴리스틱 적용
문항 독립성 가정	문항 간 상호작용(시너지/상쇄) 미고려	구조방정식모형(SEM) 적용
Q40 역설 해결	교차검증에서도 Q40이 JP에 기여하지 않음 확인	Q40은 제거 권장 (CITC=0.045)
문화적 제한	한국어 밈 기반 → 다른 문화권 적용 불가	문화 간 비교 연구
문항 선택 불안정성	SN 차원에서 문항 선택 빈도 53~87%로 불안정	문항 풀 확대 또는 IRT 기반 선별
적응적 임계값 표본 의존	최적 임계값(4.2~5.0)이 현재 표본 특성에 의존	N≥300에서 임계값 안정성 재검증
다수결 투표 천장 효과	파라미터 없어 과적합은 없으나 개선 폭이 제한적(+2.4%p)	가중 투표 등 확장 방법 검토

보고서 작성일: 2026년 3월 1일

데이터: v2 밌 설문 94명 중 유효 MBTI 81명 (실제 설문 데이터)

분석 코드: `src/team_e_item_optimization.py` (16개 그래프, 8개 분석 단계)

핵심 결론: In-sample에서는 36→20문항으로 +13.6%p 향상되었으나, 독립 표본 교차검증(K-Fold 100회 + MC 200회)에서 과적합 Gap 8.5%p, 정직한 개선 -1.9%p로 확인. **문항 축소 효과는 과적합에 의한 환상**입니다. 그러나 **적응적 임계값 (+2.7%p)**과 **다수결 투표(+2.4%p)**는 CV 검증에서 진짜 개선을 달성하여, "질문을 줄이지 말고 채점 방법을 바꿔라"가 최종 권장사항입니다. 로지스틱 회귀(Method 8)를 포함한 **총 8가지 방법**을 LOO-CV 및 Repeated K-Fold CV로 비교 검증했습니다 (16개 그래프).